Dự báo nồng độ bụi mịn PM2.5 và PM10 tại TP. Thủ Đức sử dụng phương pháp Học máy Thống kê

Triệu Đức Duy
MSSV: 23520392
23520392@gm.uit.edu.vn

Lê Tùng Dương
MSSV: 23520348
23520348@gm.uit.edu.vn

Đỗ Trần Thế Bảo
MSSV: 23520096
23520096@gm.uit.edu.vn

Nguyễn Đình Đại
MSSV: 23520216
23520216@gm.uit.edu.vn

Abstract

Tình trạng ô nhiễm không khí tại Việt Nam, đặc biệt là khu vực Thành phố Thủ Đức, đang ở mức báo động và ảnh hưởng trực tiếp đến sức khỏe cộng đồng (BaoMoi, 2025). Trong đó, bụi mịn PM2.5 và PM10 là hai tác nhân chính gây hại cho hệ hô hấp (World Health Organization, 2021). Báo cáo này trình bày việc áp dụng các phương pháp Học máy Thống kê để giải quyết bài toán dự báo ngắn hạn nồng độ hai loại bụi này. Dựa trên tập dữ liệu chuỗi thời gian bao gồm các thông tin về thời gian, điều kiện thời tiết (nhiệt độ, độ ẩm, gió...) và nồng độ các chất ô nhiễm hiện tại, chúng tôi xây dựng mô hình dự đoán nồng độ PM2.5 và PM10 cho 1, 2 và 3 giờ tiếp theo. Kết quả nghiên cứu nhằm hỗ trợ người dân chủ động bảo vệ sức khỏe, đồng thời cung cấp thông tin hữu ích cho công tác cảnh báo và quản lý chất lượng không khí.

1 Introduction

Hiện nay, tình trạng ô nhiễm không khí tại Việt Nam, đặc biệt là khu vực Thành phố Thủ Đức, đang ở mức báo động (BaoMoi, 2025). Sự phát triển công nghiệp và đô thị hóa nhanh chóng đã kéo theo sự gia tăng đáng kể các chất ô nhiễm. Báo cáo này tập trung vào việc áp dụng các phương pháp Học máy Thống kê để giải quyết vấn đề dự báo chất lượng không khí dựa trên dữ liệu thu thập được.

1.1 Motivation

Trong số các chất gây ô nhiễm không khí, bụi mịn PM2.5 và PM10 là hai tác nhân có ảnh hưởng nghiêm trọng nhất đến hệ hô hấp của con người (World Health Organization, 2021). Việc tiếp xúc lâu dài với nồng độ bụi cao có thể dẫn đến nhiều bệnh lý nguy hiểm.

Mục tiêu của chúng tôi là xây dựng mô hình dự báo chính xác và kịp thời nồng độ của các chất này. Điều này mang lại hai lợi ích chính:

- Hỗ trợ người dân chủ động bảo vệ sức khỏe khi ra đường (đeo khẩu trang, hạn chế hoạt động ngoài trời).
- Cung cấp thông tin cho chính quyền để khoanh vùng (zoning) các khu vực và thời điểm ô nhiễm tăng cao, từ đó đề xuất giải pháp cải thiện chất lượng không khí.

1.2 Problem Definition

Chúng tôi thực hiện xây dựng một ứng dụng dự báo nồng độ PM2.5 và PM10 trong ngắn hạn (tương lai gần).

Input: Dữ liệu là một chuỗi thời gian (time series), trong đó mỗi quan sát bao gồm các thuộc tính tại thời điểm hiện tại:

- Thời gian (Time).
- Thời tiết: Nhiệt độ (temp), Tình trạng thời tiết (weather), Gió (wind), Độ ẩm (RH), Áp suất (P).
- Nồng độ các chất khí ô nhiễm: CO, NO, NO_2, O_3, SO_2, NH_3.

Output: Giá trị dự báo nồng độ của PM2.5 và PM10 trong 1 giờ, 2 giờ và 3 giờ tiếp theo kể từ thời điểm hiện tại.

2 Data Collection and Analysis

2.1 Data Crawling

Dữ liệu được thu thập từ hai nguồn chính là *Time and Date* và *Open Weather Map* trong khoảng thời gian từ tháng 09/2021 đến tháng 08/2025.

- **Time and Date:** Nhóm sử dụng Python, Selenium và Webdriver để mô phỏng quá trình thu thập dữ liệu thủ công. Quy trình bao gồm phân tích URL theo khu vực/thời gian và lọc các phần tử HTML theo ID, Class.

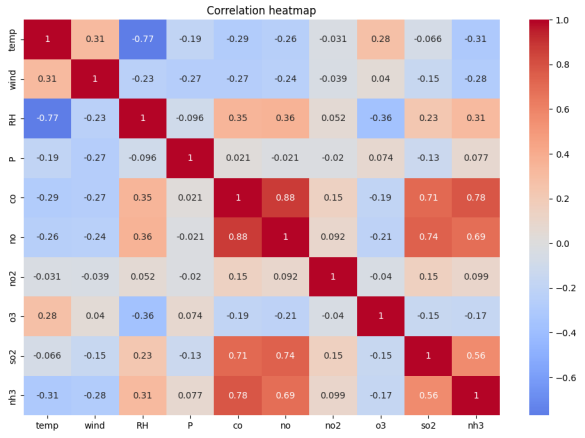


Figure 1: Biểu đồ nhiệt (Heatmap) thể hiện tương quan giữa các biến.

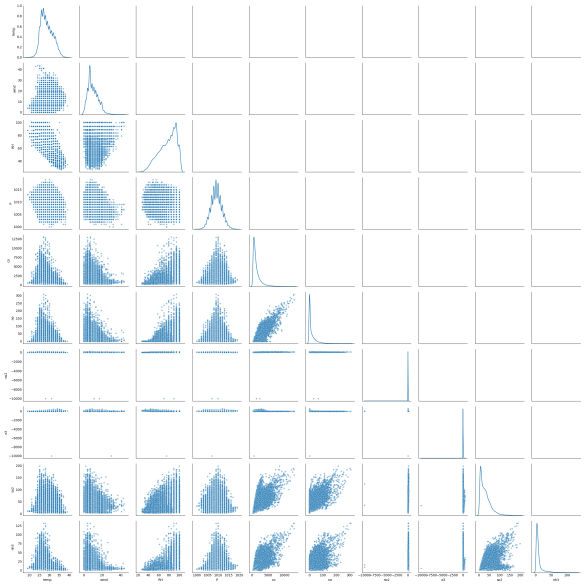


Figure 2: Phân phối dữ liệu và quan hệ giữa các biến đặc trưng.

- **Open Weather Map:** Sử dụng API với kinh độ và vĩ độ của khu vực khảo sát để lấy dữ liệu nồng độ chất ô nhiễm.
- **Tiền xử lý:** Dữ liệu PM2.5 và PM10 của 3 dòng tiếp theo (tương ứng 3 giờ tới) được trượt (shift) lên dòng hiện tại để tạo thành 6 cột nhãn mục tiêu (target label).

2.2 Data Analysis

Sau khi thu thập và gán nhãn, bộ dữ liệu có hơn 35.000 dòng. Dữ liệu được chia thành: Train (75%, 9/2021-8/2024), Valid (12.5%, 9/2024-2/2025) và Test (12.5%, 3/2025-8/2025). Hầu hết các cột đều chứa giá trị rỗng (null) và ngoại lai (outlier), ngoại trừ cột thời gian.

Data Types:

- **Datetime:** time.
- **Float64:** temp, wind, RH, P, co, no, no_2, o_3, so_2, pm2_5, pm10, nh_3 và các cột target (next1, next2, next3).
- **Object:** weather.

Correlation Analysis: Trong hơn 80 kiểu thời tiết, thường chỉ có một kiểu chủ đạo trong cùng khung giờ và kéo dài hàng giờ. Dựa vào Hình 1 và Hình 2:

- Các biến CO, NO, SO_2, NH_3 có tương quan dương mạnh, cho thấy chúng thường đồng xuất hiện trong không khí ô nhiễm.
- Nhiệt độ (temp) và độ ẩm (RH) có tương quan âm.
- Dữ liệu CO, NO, NH_3 bị lệch phải (skewed right), cho thấy sự tồn tại của các giá trị cực đoan.

Time Trends: Dữ liệu cho thấy các xu hướng rõ ràng và có tính chu kỳ. Ngoại trừ O_3, nồng độ các chất ô nhiễm thường thấp từ tháng 2-5 và cao hơn trong phần còn lại của năm.

- **Tháng 2-5:** Sự xáo trộn khí quyển mạnh và hoạt động nhân sinh thấp giúp giảm phát thải.
- **Mùa hè/Đầu đông:** Thời tiết nóng ẩm thúc đẩy phân hủy sinh học (tăng NH_3, NO_x). Du lịch hè cũng làm tăng khí thải.
- **Cuối năm:** Hiện tượng nghịch nhiệt giữ chất ô nhiễm gần mặt đất, cộng với việc đốt than/rác làm tăng nồng độ ô nhiễm (xem Hình 4).

Daily Patterns: Khung giờ trong ngày ảnh hưởng lớn đến các biến số. Nhiệt độ thấp vào đêm (22h-9h) và cao vào trưa. Đặc biệt, khung giờ 7h-9h sáng có nồng độ ô nhiễm cao nhất do hoạt động giao thông.

2.3 Pattern Mining

Nhóm áp dụng thuật toán **Apriori** và **PrefixSpan** trên dữ liệu phân loại (Weather) để tìm các mẫu phổ biến:

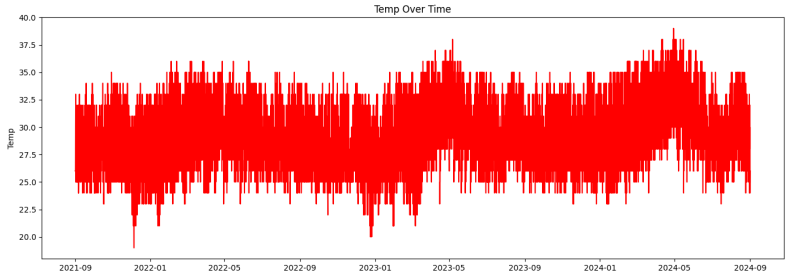


Figure 3: Biến thiên nhiệt độ theo thời gian.

Nhận xét: Nhiệt độ dao động trong khoảng 20-38°C. Mức nhiệt tăng cao từ tháng 3 đến tháng 7 và giảm thấp từ tháng 12 đến tháng 2 năm sau.

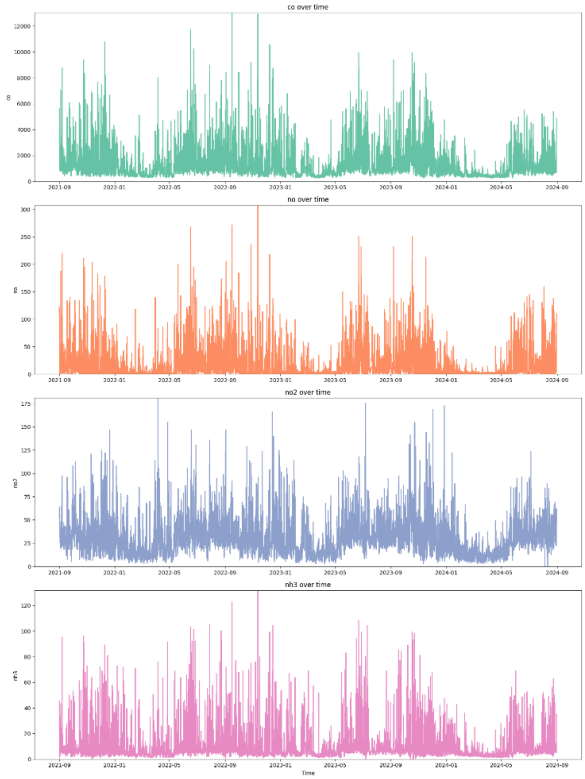


Figure 4: Nồng độ CO theo thời gian.

- Các kiểu thời tiết không mưa (chứa 'cloud', 'sun') thường kéo dài nhiều giờ.
- Các kiểu thời tiết cực đoan (chứa 'rain', 'fog', 'thunder') thường chỉ kéo dài 1-2 giờ.

3 Data Preprocessing

Để đảm bảo chất lượng dữ liệu đầu vào cho mô hình, chúng tôi thực hiện quy trình tiền xử lý bao gồm xử lý giá trị thiếu (missing values) và xử lý điểm ngoại lai (outliers).

3.1 Missing Values Handling

Dữ liệu số (Numerical Columns): Chúng tôi áp dụng phương pháp nội suy bậc ba (Cubic Interpolation) kết hợp với kỹ thuật điền xuôi (Forward fill) và điền ngược (Backward fill) để lấp đầy các giá trị còn thiếu. Công thức nội suy spline bậc ba được định nghĩa như sau:

$$S_i(x) = a_i + b_i(x - x_i) + c_i(x - x_i)^2 + d_i(x - x_i)^3 \quad (1)$$

với $x \in [x_i, x_{i+1}]$.

Dữ liệu phân loại (Categorical Columns): Đối với cột Weather, nhóm sử dụng kỹ thuật **Rolling Majority Window**. Cụ thể, áp dụng một cửa sổ trượt để tìm giá trị xuất hiện nhiều nhất (mode) trong vùng lân cận và điền vào chỗ trống. Nếu vẫn còn giá trị thiếu (NaNs), chúng tôi điền bằng giá trị mode của chính giờ đó trên toàn bộ tập dữ liệu.

3.2 Outliers Handling

Việc xử lý điểm ngoại lai trên các cột số được thực hiện qua 3 bước nghiêm ngặt:

- **Bước 1:** Tính trung bình các giá trị không âm trong cột và thay các giá trị âm bằng giá trị trung bình này để đúng với ý nghĩa vật lý của giá trị.
- **Bước 2 (Phát hiện):** Sử dụng phương pháp IQR để phát hiện các giá trị ngoại lai, cụ thể là các giá trị bé hơn

$$lower = Q1 - 1.5 \times IQR \quad (2)$$

hoặc lớn hơn

$$upper = Q3 + 1.5 \times IQR \quad (3)$$

, với $Q1$, $Q3$ lần lượt là tứ phân vị thứ nhất và tứ phân vị thứ ba sau khi đã thay các giá trị âm ở bước 1
- **Bước 3 (Thay thế):** Cắt các giá trị ngoại lai về $lower$ hoặc $upper$ tương ứng

4 Feature Engineering

4.1 Data Transformation

Một số cột dữ liệu có phân phối bị lệch (skewed) được áp dụng phép biến đổi Log (Log transform). Kỹ thuật này giúp dữ liệu trở nên cân đối hơn và tiệm cận với phân phối chuẩn, điều này là cần thiết để tối ưu hóa hiệu suất của một số thuật toán học máy.

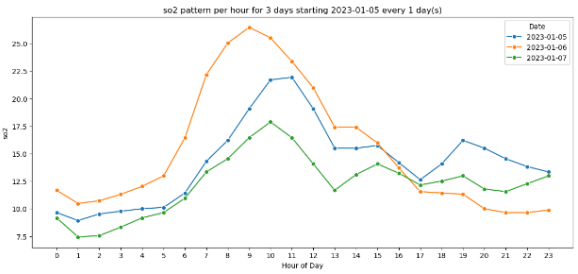


Figure 5: Mô hình nồng độ SO_2 theo giờ.

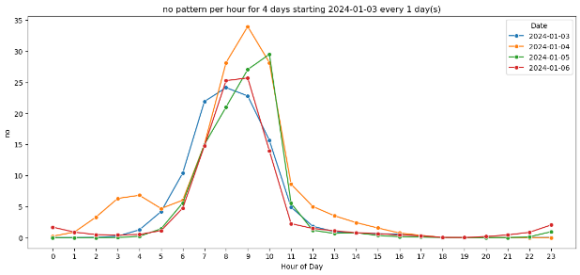


Figure 6: Mô hình nồng độ NO theo giờ.

4.2 Feature Creation

Để tăng cường khả năng học của mô hình, chúng tôi tạo ra các đặc trưng mới (new features) dựa trên dữ liệu gốc:

- **Rank Encoding (Cho dữ liệu phân loại):** Với mỗi giá trị phân loại, chúng tôi tính trung bình của biến mục tiêu tương ứng, sau đó sắp xếp chúng thành các thứ hạng (rank). Giá trị rank này được dùng làm đặc trưng mới thay thế cho nhãn phân loại ban đầu.
- **Time Features:** Chuyển đổi cột thời gian sang định dạng datetime và trích xuất các thông tin: Năm, Tháng, Ngày, Thứ trong tuần (Weekday) và Giờ. Điều này giúp mô hình nắm bắt được các mẫu hình theo thời gian (temporal patterns).
- **Lag Features (Đặc trưng trễ):** Tạo các đặc trưng trễ ngắn hạn (1-24 giờ) bằng cách trượt dữ liệu quá khứ. Các giá trị thiếu do trượt được điền bằng nội suy. Đây là thông tin quan trọng cung cấp ngữ cảnh lịch sử gần nhất cho dự báo ngắn hạn.
- **Rolling Mean Features:** Sử dụng các cửa sổ trượt dài hạn (30 ngày, 60 ngày, 360 ngày) để tính toán trung bình động. Các đặc trưng này giúp nắm bắt xu hướng dài hạn (trend) và tính mùa vụ (seasonality), đồng thời giảm thiểu nhiễu tạm thời.

Kết thúc quá trình tiền xử lý và kỹ thuật đặc trưng, bộ dữ liệu hiện tại bao gồm **157 đặc trưng (features)** và đã sẵn sàng cho giai đoạn huấn luyện mô hình.

5 Modeling

5.1 Hyper-parameter Tuning Method

Để tối ưu hóa hiệu suất mô hình, nhóm sử dụng thư viện **Optuna** để tự động tìm kiếm các siêu tham số (hyperparameters) tốt nhất.

- Optuna sử dụng phương pháp tối ưu hóa Bayes (Bayesian optimization).
- Áp dụng kỹ thuật cắt tỉa (pruning) và thực thi song song (parallel execution) để tiết kiệm thời gian và tài nguyên tính toán.

5.2 Used Models

a. ElasticNet: Mô hình này được sử dụng làm cơ sở (baseline) để so sánh. Nó có khả năng mô phỏng các mối quan hệ phức tạp mà không giả định quan hệ tuyến tính giữa các biến.

b. LightGBM: Đây là thuật toán dựa trên Gradient Boosting, có ưu điểm là tốc độ huấn luyện cao và tiết kiệm tài nguyên.

c. XGBoost: XGBoost là thuật toán thường đạt kết quả cao trong các cuộc thi Machine Learning. Cũng sử dụng Gradient Boosting nhưng XGBoost phát triển cây theo tầng (level-wise), khác với cơ chế phát triển theo lá (leaf-wise) của LightGBM.

d. Random Forest Regressor: Đây là phương pháp cải tiến của Decision Tree sử dụng cơ chế học kết hợp bagging (bagging ensemble), giúp tăng độ chính xác và giảm thiểu hiện tượng quá khớp (overfit).

6 Kết quả, Kết luận

6.1 Đánh giá các mô hình dự báo PM2.5 khác

Chúng tôi tiến hành đánh giá hiệu suất của các mô hình Machine Learning truyền thống (LightGBM, XGBoost, Random Forest...) trong việc dự báo nồng độ PM2.5.

6.2 Đánh giá các mô hình dự báo PM10

Tương tự, dưới đây là bảng kết quả đánh giá hiệu suất của các mô hình đối với bài toán dự báo nồng độ PM10.

		RMSE		R2		Pearson	
PM2.5 in next 1 hour	ElasticeNet	32.6179	39.5083	0.7083	0.6583	0.8434	0.8284
	XGBoost	10.6531	28.8023	0.9689	0.8184	0.9846	0.9121
	LightGBM	10.6370	12.9206	0.9690	0.9635	0.9846	0.9820
	Random Forest	***8.6341***	***29.3244***	***0.9796***	***0.8118***	***0.9901***	***0.9029***
PM2.5 in next 2 hour	ElasticeNet	34.6331	42.5746	0.6712	0.6030	0.8209	0.7924
	XGBoost	14.7306	35.9935	0.9405	0.7162	0.9705	0.8505
	LightGBM	14.4476	18.0898	0.9428	0.9283	0.9716	0.9649
	Random Forest	***11.3050***	***37.1474***	***0.9650***	***0.6977***	***0.9833***	***0.8365***
PM2.5 in next 3 hour	ElasticeNet	37.1736	46.5294	0.6212	0.5254	0.7895	0.7395
	XGBoost	18.7600	44.1538	0.9035	0.5726	0.9522	0.7596
	LightGBM	15.8211	19.1568	0.9314	0.9196	0.9659	0.9611
	Random Forest	***13.6816***	***45.5539***	***0.9487***	***0.5451***	***0.9762***	***0.7392***

Figure 7: Bảng so sánh kết quả đánh giá các mô hình dự báo PM2.5 trên tập Training và Validation.

6.3 So sánh với mô hình Open-Meteo API trên tập Test

Sau khi chọn được mô hình tốt nhất, nhóm thực hiện đánh giá sai số thực tế trên tập kiểm tra (Test set) và so sánh đối chứng với kết quả dự báo từ Open-Meteo API (một dịch vụ dự báo thời tiết phổ biến).

Nhận xét: Như thể hiện trong Hình 9, mô hình đề xuất của chúng tôi đạt sai số thấp hơn, cải thiện từ **3 đến 10** $\mu g/m^3$ so với kết quả được cung cấp bởi API Open-Meteo. Điều này chứng minh tính hiệu quả và độ chính xác cao hơn của mô hình được xây dựng đặc thù cho khu vực nghiên cứu.

References

BaoMoi. 2025. Chất lượng không khí tại tp hcm và nguy cơ sức khỏe. https://baomoi.com/tp-hcm-nam-trong-nhom-10-thanh-pho-o-nhiem-nhat-the-gioi-c53999692.epi. Accessed: 2025-01-03.

World Health Organization. 2021. *WHO global air quality guidelines: particulate matter (PM2.5 and PM10), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide*. World Health Organization, Geneva.

		RMSE		R2		Pearson	
PM10 in next 1 hour	ElasticeNet	39.1975	44.7087	0.7221	0.6897	0.8507	0.8457
	XGBoost	***7.0031***	***32.0013***	***0.9911***	***0.8410***	***0.9957***	***0.9177***
	LightGBM	7.5624	32.4377	0.9897	0.8367	0.9948	0.9151
	Random Forest	9.1144	35.9814	0.9850	0.7990	0.9934	0.8991
PM10 in next 2 hour	ElasticeNet	42.0266	49.2179	0.6806	0.6238	0.8258	0.8044
	XGBoost	***10.3335***	***41.0760***	***0.9807***	***0.7380***	***0.9906***	***0.8603***
	LightGBM	10.8742	41.4943	0.9786	0.7326	0.9893	0.8562
	Random Forest	11.6103	44.3395	0.9756	0.6947	0.9896	0.8394
PM10 in next 3 hour	ElasticeNet	45.3979	54.4964	0.6273	0.5385	0.7927	0.7463
	XGBoost	***13.3745***	***51.3715***	***0.9677***	***0.5899***	***0.9846***	***0.7699***
	LightGBM	13.7359	54.5838	0.9659	0.5371	0.9830	0.7337
	Random Forest	13.6982	52.9583	0.9661	0.5642	0.9865	0.7614

Figure 8: Bảng so sánh kết quả đánh giá các mô hình dự báo PM10 trên tập Training và Validation.

	PM2.5+1	PM2.5+2	PM2.5+3	PM10+1	PM10+2	PM10+3
MVP Model	**13.8985** (Random Forest)	**13.5155** (Random Forest)	**14.5319** (Random Forest)	**14.9962** (XGBoost)	**19.2648** (XGBoost)	**20.8459** (XGBoost)
Baseline prediction (OpenMeteo API)	29.0451	29.049	29.0521	34.5085	34.5116	34.514

Figure 9: Biểu đồ so sánh sai số (Error) giữa mô hình đề xuất và Open-Meteo API trên tập Test.